

DESAFIO 2

Modelagem Preditiva e Dashboard Interativo

Ciência e Governança de Dados - Zetta Lab

Projeto:	Análise de Impactos Socioeconômicos na Educação Brasileira
Autor:	Gustavo Teodoro
Período Analisado:	2018-2022
Data de Entrega:	05 de February de 2026
Status:	Completo e Pronto para Avaliação

REPOSITÓRIO GITHUB

<https://github.com/tteodorogustavo/ZettaLab-Data>

DESCRIÇÃO DO PROJETO

O Desafio 2 expandiu a análise do Desafio I através da extensão temporal dos dados (2018-2022), incorporação de variáveis socioeconômicas adicionais (IDHM, desemprego, renda, Gini, gravidez adolescente, PIB), desenvolvimento de modelos preditivos avançados (Regressão Linear, Random Forest, XGBoost), interpretabilidade via SHAP analysis, sistema de classificação de risco e um dashboard interativo com 6 páginas Streamlit.

METODOLOGIA CRISP-DM

O projeto segue rigorosamente as 7 fases da metodologia CRISP-DM (Cross Industry Standard Process for Data Mining): (1) Entendimento do Negócio, (2) Entendimento dos Dados, (3) Preparação dos Dados, (4) Modelagem, (5) Avaliação, (6) Implantação e (7) Monitoramento/Dashboard.

PRINCIPAIS RESULTADOS

Métrica	Desafio I	Desafio II
Variáveis Preditivas	2	6

Registros	27	135
R ² Modelo	0.15	0.51
Interpretabilidade	Baixa	Alta (SHAP)

DESCOBERTAS PRINCIPAIS

1. Gravidez Adolescente como Principal Preditor (63.5%)

Gravidez adolescente emerge como o fator de maior importância para prever abandono escolar, refletindo desigualdades sociais profundas. Estados com taxas >20% apresentam 3x maior risco de evasão.

2. Necessidade Multidimensional

Abandono escolar é fenômeno multifatorial que engloba vulnerabilidade social, desigualdade econômica, capacidade econômica e desenvolvimento humano. Uma abordagem unidimensional é insuficiente.

3. Melhoria Significativa do Modelo

A incorporação de indicadores socioeconômicos multidimensionais aumentou o R² de 0.15 (Desafio I) para 0.51 (Desafio II), representando uma melhoria de 240%.

ESTRUTURA DO REPOSITÓRIO

Notebooks CRISP-DM:

- 01_EDA.ipynb - Análise exploratória
- 02_Preparacao_Dados.ipynb - Consolidação de dados INEP
- 03_Integracao_Dados.ipynb - Combinação de datasets
- 04_modelagem_regressao.ipynb - Treinamento de modelos
- 05_avaliacao_shap.ipynb - SHAP analysis
- 06_classificacao_risco.ipynb - Categorização por quartis
- 07_solucoes_classificacao.ipynb - Abordagem híbrida
- 08_otimizacao_hiperparametros.ipynb - GridSearch
- 09_justificacao_thresholds_risco.ipynb - Thresholds políticos

Dashboard:

- dashboard/app.py - Aplicação Streamlit
- 6 páginas interativas com filtros e gráficos
- Integração com modelo XGBoost otimizado

Dados:

- data/Raw/ - Dados brutos de INEP, IBGE, Atlas Brasil
- data/Processed/ - Dataset final (135x14)
- data/vizualizations/ - Gráficos e imagens

COMO EXECUTAR O PROJETO

1. Clonar o Repositório

```
git clone https://github.com/tteodorogustavo/ZettaLab-Data.git
cd ZettaLab-Data
```

2. Configurar Ambiente Virtual

```
python -m venv venv
source venv/bin/activate # No macOS/Linux
venv\Scripts\activate # No Windows
```

3. Instalar Dependências

```
pip install -r requirements.txt
```

4. Executar Dashboard

```
streamlit run dashboard/app.py
```

5. Explorar Notebooks

```
jupyter notebook
```

Abra os arquivos em notebooks/ na ordem recomendada (01 → 02 → 04 → 05)

TECNOLOGIAS UTILIZADAS

Análise de Dados: Pandas, NumPy

Modelagem: Scikit-learn, XGBoost

Interpretabilidade: SHAP

Visualização: Matplotlib, Seaborn, Plotly

Geoespacial: Folium, GeoPandas

Dashboard: Streamlit

Versão Control: Git, GitHub

RESULTADOS DA MODELAGEM

Modelo	MAE	RMSE	R ²
Regressão Linear	0.804	1.073	0.180
Random Forest	0.675	0.927	0.387
XGBoost (baseline)	0.665	0.899	0.425
XGBoost (otimizado)	0.598	0.841	0.510

IMPORTÂNCIA DAS VARIÁVEIS (SHAP)

Ranking	Variável	Importância	Interpretação
1	Taxa Gravidez Adolescente	63.5%	Principal preditor
2	Renda Per Capita	15.2%	Capacidade econômica
3	Taxa Desemprego	12.1%	Instabilidade
4	IDHM	6.8%	Desenvolvimento humano
5	Índice Gini	1.5%	Desigualdade
6	PIB Total	0.8%	Economia agregada

SISTEMA DE CLASSIFICAÇÃO DE RISCO (2022)

Estado	Taxa Evasão	Classificação
Pará	4.45%	Alto Risco
Bahia	4.00%	Alto Risco
Roraima	3.90%	Alto Risco
Acre	3.80%	Alto Risco
Paraíba	3.40%	Alto Risco

INSTRUÇÕES PARA OS AVALIADORES

1. Acessar o Repositório

Visite o repositório GitHub no link fornecido para visualizar todo o código, documentação e commits.

2. Explorar o README

O README contém documentação completa com:

- Descrição detalhada de cada seção
- Explicação sobre adição de novos dados (Seção 3.4)
- Visualizações dos resultados (Seção 6.1)
- Guia Quick Start para execução
- Links para dados e fontes

3. Revisar os Notebooks

Todos os 9 notebooks seguem a metodologia CRISP-DM e incluem:

- Código limpo e bem documentado
- Tratamento de erros robusto
- Visualizações informativas
- Explicações científicas

4. Testar o Dashboard

Clone o repositório e execute:

```
streamlit run dashboard/app.py
```

O dashboard oferece 6 páginas interativas com análises em tempo real.

5. Verificar Commits

Todos os commits incluem mensagens descritivas que documentam:

- Qualidade de revisão dos notebooks
- Melhorias implementadas
- Adições de documentação
- Limpeza de arquivos temporários

INFORMAÇÕES DE CONTATO

LinkedIn:	https://www.linkedin.com/in/gustavo-teodoro-55917b282/
Email:	gustavo.teodoro1@estudante.ufla.br
GitHub:	https://github.com/tteodorogustavo